

El algoritmo Metropolis-Hastings se puede resumir de la forma siguiente:

1. Definir un valor inicial  $\theta^{(0)}$ ,

2.  $t = 0$ ,

3. Generar  $\phi \sim g(\cdot|\theta^{(t)})$ ,

4. Definir

$$\alpha(\theta^{(t)}, \phi) = \min \left[ 1, \frac{f(\phi|\mathbf{x}) \cdot g(\theta^{(t)}|\phi)}{f(\theta^{(t)}|\mathbf{x}) \cdot g(\phi|\theta^{(t)})} \right]$$

5. Tomar

$$\theta^{(t+1)} = \begin{cases} \phi & \text{con probabilidad } \alpha \\ \theta^{(t)} & \text{en caso contrario} \end{cases}$$

6.  $t = t + 1$ . Ir a 3.

Se puede demostrar que mediante este algoritmo se simula una muestra de una cadena de Markov cuya distribución estacionaria es  $f(\theta|\mathbf{x})$ .

En teoría, se puede utilizar cualquier distribución  $g(\phi|\theta)$ . Lo más importante es que sea fácil de muestrear, aunque la convergencia del algoritmo será más rápida si  $g \approx f$ .

### Comprobación de la convergencia

(i) Comparación de los resultados con valores iniciales diferentes.

(ii) Gráficos de los valores  $\theta^{(t)}$ .

(iii) Gráficos de la media estimada (*running means*) de  $\theta$ .

(iv) Diagnósticos formales de convergencia.

Habitualmente, se usa la primera parte de los datos generados por la cadena de Markov como datos de *burn-in* para que la cadena *olvide* su estado inicial, de modo que para la estimación sólo se utiliza la última parte de los datos generados.

Se estima (por ejemplo) la media a posteriori de  $\theta$  usando

$$E[\theta|\mathbf{x}] \approx \frac{1}{N-M} \sum_{t=M+1}^N \theta^{(t)},$$

donde  $M$  es el número de iteraciones de *burn-in* y  $N$  es el número total de iteraciones.