

Next Up Previous

Next: [3 Convergencia](#) Up: [2 Monte Carlo vía](#) Previous: [1 Algoritmo de Metropolis-Hastings](#)

2 Muestreo de Gibbs

Al igual que el algoritmo de Metropolis, el algoritmo de Gibbs permite simular una cadena de Markov $\theta^{(1)}, \theta^{(2)}, \dots$ con distribución de equilibrio $p(\theta|x)$. En este caso, sin embargo, cada nuevo valor de la cadena se obtiene a través de un proceso iterativo que sólo requiere generar muestras de distribuciones cuya dimensión es menor que d y que en la mayoría de los casos tienen una forma más sencilla que la de $p(\theta|x)$.

Sea $\theta = (\theta_1, \dots, \theta_k)$ una partición del vector θ , donde $\theta_i \in \mathbb{R}^{d_i}$ y $\sum_{i=1}^k d_i = d$. Las densidades

$$\begin{array}{c} p(\theta_1 | \theta_2, \dots, \theta_k, x) \\ \vdots \\ p(\theta_i | \theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_k, x) \quad (i = 2, \dots, k-1) \\ \vdots \\ p(\theta_k | \theta_1, \dots, \theta_{k-1}, x) \end{array}$$

se conocen como *densidades condicionales completas* y en general pueden identificarse fácilmente al inspeccionar la forma de la distribución final $p(\theta|x)$. De hecho, para cada $i = 1, \dots, k$,

$$p(\theta_i | \theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_k, x) \propto p(\theta|x),$$

donde $p(\theta|x) = p(\theta_1, \dots, \theta_k|x)$ es vista sólo como función de θ_i .

Dado un valor inicial $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_k^{(0)})$, el algoritmo de Gibbs simula una cadena de Markov en la que $\theta^{(t+1)}$ se obtiene a partir de $\theta^{(t)}$ de la siguiente manera:

generar una observación $\theta_1^{(t+1)}$ de $p(\theta_1 | \theta_2^{(t)}, \theta_3^{(t)}, \dots, \theta_k^{(t)}, x)$;

generar una observación $\theta_2^{(t+1)}$ de $p(\theta_2 | \theta_1^{(t+1)}, \theta_3^{(t)}, \dots, \theta_k^{(t)}, \mathbf{x})$;

\vdots

generar una observación $\theta_k^{(t+1)}$ de $p(\theta_k | \theta_1^{(t+1)}, \theta_2^{(t+1)}, \dots, \theta_{k-1}^{(t+1)}, \mathbf{x})$.

La sucesión $\theta^{(1)}, \theta^{(2)}, \dots$ así obtenida es entonces una realización de una cadena de Markov cuya distribución de transición está dada por

$$P(\theta^{(t+1)} | \theta^{(t)}) = \prod_{i=1}^k p(\theta_i^{(t+1)} | \theta_1^{(t+1)}, \dots, \theta_{i-1}^{(t+1)}, \theta_{i+1}^{(t)}, \dots, \theta_k^{(t)}, \mathbf{x}).$$

Comentario. En ocasiones la distribución final implica cierta estructura de independencia condicional entre algunos de los elementos del vector θ . En estos casos es común que muchas de las densidades condicionales completas se simplifiquen.

Ejemplo 5.1 Consideremos el modelo jerárquico definido por

- I. $p(\mathbf{x} | \omega) = \prod_{i=1}^m p(x_i | \omega_i)$;
- II. $p(\omega | \phi) = \prod_{i=1}^m p(\omega_i | \phi)$;
- III. $p_0(\phi)$.

Esta estructura define un modelo para \mathbf{x} parametrizado por $\theta = (\omega, \phi) = (\omega_1, \dots, \omega_m, \phi)$ y con distribución inicial $p(\theta) = p_0(\phi) p(\omega | \phi)$, de manera que la distribución final está dada por

$$p(\theta | \mathbf{x}) \propto p_0(\phi) \prod_{i=1}^m \{p(x_i | \omega_i) p(\omega_i | \phi)\}.$$

Entonces $k = m + 1$ y las densidades condicionales completas toman la forma

$$p(\theta_1 | \theta_2, \dots, \theta_{k-1}, \theta_k, \mathbf{x}) = p(\omega_1 | \phi, x_1)$$

\vdots

\vdots

$$p(\theta_{k-1} | \theta_1, \dots, \theta_{k-2}, \theta_k, \mathbf{x}) = p(\omega_m | \phi, x_m)$$

$$p(\theta_k | \theta_1, \dots, \theta_{k-2}, \theta_{k-1}, \mathbf{x}) = p_0(\phi | \omega),$$

donde $p_0(\phi | \omega) \propto p_0(\phi) p(\omega | \phi)$.